

AB TEST - One Page



A/B实验背后的统计学模型是（双样本）假设检验

一、统计学基础

1. 一类错误、二类错误

第1类错误为弃真错误，**即原假设是正确的，却拒绝了原假设**。即这个功能的改变不能带来改进，但是我们却以为能带来收益，也就是**“我的策略其实没用，但是实验结果却显示我的策略有用。”**这种情况下，如果实行了这种改动，可能会对用户的留存等等产生较大的影响，所以相较于第二类错误，对这一类错误会要求得比较严格。

第2类错误为取伪错误，**即原假设是错误的但却接受了原假设**。即这个功能的改变本来是可以带来收益的，但是却误判以为不能带来收益。也就是**“我的策略其实有用，但是我没有检测出来。”**这种情况最差就是仍然保持原状，不会造成较大的影响，所以相较于第1类错误会比较宽松。

2. 中心极限定理，大数律定理

中心极限定理描述的是：在满足样本相互独立、来自同一分布、方差有限的情况下，当样本容量足够大时，**样本均值（或样本和）的分布将近似服从正态分布**，无论原始总体的分布形态如何。也就是说，即使总体分布是偏态的、离散的或非正态的，只要样本量足够大，样本均值的抽样分布都会趋近于正态分布，其均值为总体均值，方差为总体方差除以样本量。

大数律定理描述的是：在相同条件下，当样本容量不断增大时，**样本均值会以概率 1（或概率趋近于 1）的方式收敛到总体的真实均值**。直观理解就是：样本量越大，平均值越稳定，越接近真实期望值，随机波动的影响会被不断“抵消”。大数律保证了用样本均值去估计总体均值是**一致的、可靠的**。

3. 显著性水平 α



A/B实验背后的统计学理论是双样本假设检验。统计过程中，我们可能犯**第一类错误——弃真**，在统计学中，**显著性水平（ α ）用于描述实验者犯第一类错误的概率。**

A. 为什么要规定显著性水平（量化抽样误差不确定性有多大）

在实际业务中，无论是感性、理性还是经验，都很难保证我们对产品作出的更改策略是正确的。一个按钮从蓝色改成红色，一个窗口从左边移到右边，到底用户体验会变好还是变差呢？我们并不确定。

因此我们需要通过A/B实验，帮助我们**转化**这种“**不确定**”——观察小流量实验中新旧策略的表现，从而确定新旧策略的优劣。

但是，这样就能完全消除不确定性了吗？仍旧不能。因为在统计过程中存在**抽样误差**。

举个例子：假设在1%的流量下，组A（按钮呈红色）比组B（按钮呈现蓝色）购买率高。将流量扩大至100%，能保证策略A的表现仍旧比策略B出色吗？显然，我们还是**不确定**。


抽样误差带来的**不确定性**，使得我们在做小流量实验时，永远没法保证结论是完全正确的。幸运的是，针对抽样的不确定性，在统计学中，我们有一套方法来**量化这种不确定性到底有多大。这便是显著性水平（ α ）存在的意义。**

B. 显著性水平的理论依据

我们可以量化抽样误差的根基在于**中心极限定理**的存在。

由于存在抽样误差，我们每次实验所得到的指标结果，都可能与我们期望得到的真正结果有误差。假设我们从总体中抽取样本，计算其指标的均值，每一次计算，样本均值都会受抽样误差影响。假如我们做无数次实验，那么理论上，这无数多个样本均值中，总应该有一个是“真的”，不受抽样误差影响的，这个值在统计学里被称为“**真值**”。

了解了这些，再来看看什么是中心极限定理。为了便于理解，我们不对这一定理的统计学概念做叙述，仅从A/B实验场景下出发，解释中心极限定理。中心极限定理告诉我们：如果从总体流量里不断抽取样本，做无数次小流量实验，这无数次抽样所观测到的均值，近似呈现**正态分布**。这个分布以真值为中心，**均值越接近真值，均值出现的概率就越大；均值越偏离真值，出现的概率就越小。**



(正态分布示意)

为什么样本均值越接近真值，均值出现的概率越大呢？用人均收入来类比：如果从全中国人这个总体中，抽取很多很多次样本，计算很多很多次平均收入。可以预见，我们会因为样本不同而得到很多个不同的平均收入值。这些数值确实有可能因为偶然抽到顶级富豪而偏高，或因为抽到极贫困的人口而偏低。但是，上述两种情况毕竟是少数（均值越偏离真值，出现的概率越小）。随着抽样次数增多，


我们会发现，平均收入落在大多数普通人收入范围内的次数，会显著增多（均值接近真值，出现的概率大）。并且，有了中心极限定理的帮助，我们可以知道每个均值出现的概率是多少。

C. 实验中显著性水平的应用

了解了显著性水平的理论依据，我们该怎么利用显著性水平，来评判我的新策略是否有用呢？假设我现在要进行一个实验，看看新策略会不会提升产品的人均阅读数。

- 原策略记为A1
- 新策略记为A2。

为了方便理解，我们再假设，原策略A1生效时，全流量下（总体用户）的人均阅读数真值是10。如果我对全流量推广原策略A1，并从中不断抽样，根据中心极限定理，我们可以知道，不断抽样所得到的



现在我们从总流量中抽取一小部分样本，对样本实施新策略A2，并得到一个人均阅读数x。现在问题来了，怎么评判新策略A2有用没用呢？（我们假设人均阅读数的标准差是2，如图，人均阅读数间隔是2）

先看图中靠近10的深蓝色区域，在原策略A1生效时，单凭抽样误差，人均阅读数就很可能落在这一区域里。如果新策略A2生效时，人均阅读数x也落在这一区域里，我们就很难确定新策略A2到底有没有用。因为单凭抽样误差，也可以得到与x一样的值。

假如x值落在12~14这个区域里呢？从图中我们可以发现，单凭抽样的随机性，x落在这一区的概率下降了（概率从34.1%下降至13.6%）。直觉上来说，我们的新策略可能是产生了一定影响，才使得x落

在了12~14这一区。

当x的值超过14呢？由图可知，旧策略A1条件下，凭借抽样误差使得人均阅读数 >14 的概率只有2.2%。如果A2组的观测结果 $x>14$ ，我们就有很大的信心表示，我的新策略A2生效了。因为，如果我们的新策略没有啥用，我们仅有2.2%的机会能在一次实验里观察到大于14的人均阅读指标。

4. P-value



p-value: 反映了“假设新策略没用（原假设成立）时，出现当前实验结果或更利好新策略的结果的概率”。

- 若 **p 值** 小于预先设定的显著性水平 α （如 Libra 平台规定的 5%），说明“新策略没用但抽到这种结果”的概率比允许的容错率还低，因此拒绝“新策略没用”的假设，认为实验结果“统计显著”，新策略**大概率有效**。
- 反之，说明“新策略没用但抽到这种结果”的概率超过了允许的容错率，无法拒绝“新策略没用”的假设，结果“不显著”，可能只是抽样误差导致的偶然现象。

逻辑链路：

1. 我们默认“新策略不生效”（原假设）；
2. 实验出现了一个“看起来新策略生效”的结果；
3. 计算 p 值：如果“新策略真的不生效”，出现这种“看起来生效”的结果（或更极端）的概率有多高？
4. 如果这个概率（p 值，小概率事件）比我们能接受的“误判风险”（ α ）还低，就说明“原假设太不合理”，因此拒绝原假设，认为“结果显著”（即“有理由相信策略可能有用”）

如果你对魔术有所了解，你就会知道魔术师们经常会使用一些tricky的小道具，比如两面都是花/字的“虚假的硬币”。现在试想一下，我站在你面前，手里握着一个硬币，你没法看到我手里的硬币，你需要回答我一个问题：我手里的硬币是真正的硬币（一面字，一面花），还是虚假的硬币（两面都是字/花）。

现在，我们开始抛硬币，对硬币向上的一面观测结果如下图所示。

真实的硬币 or 虚假的硬币

第n次抛硬币	字/花	p-value	你的心理变化
第1次	是字	0.5	正常啊 😊
第2次	是字	0.25	还行吧 😊
第3次	是字	0.125	能接受 😊
第4次	又是字	≈ 0.06	不对吧... 😊
第5次	还是字	≈ 0.03	有猫腻! 😊
第6次	怎么老是字	≈ 0.02	虚假警告! 😊
.....			

当p-value<0.05
你眉头一皱
感觉事情并不简单
或许是一个虚假的硬币

我们知道，如果硬币是正常的，投掷一次硬币，字/花朝上的可能是50%。那么正常情况下，连续不断投掷硬币，字/花朝上的比率应该接近50%。但是在实际的过程中，我们没办法一直不断的抛硬币，所以只能用有限的次数，去判断硬币是不是tricky，这就是我们所说的“抽样”。在这个检验过程中，我们设置：

- 原假设 (H_0) = 硬币是真的，并不tricky
- 备择假设 (H_1) = 硬币是虚假的，是tricky的

从图中可知，我们连投了6次硬币，每一次都是字朝上。从某一个点开始，你开始觉得事情有一些不对劲，你开始觉得：如果是真正的硬币（原假设为真的情况下），不该出现这种情况吧，似乎硬币有问题。

这就是p-value在持续下降，并超过了一个临界点（显著性水平 α ）所造成的。在统计学中，p-value就是：当原假设为真时，我们得到当前的样本观察结果或者出现更极端结果的概率。套用抛硬币这一例子，p-value就是，如果硬币是真的（原假设为真），硬币抛6次都是字朝上（当前样本观察结果），或者抛更多次都是字朝上（出现更极端结果），这种概率有多大。p-value越小，我们拒绝原假设的理由越充分，结果也就越显著。

回到上面人均阅读数的问题：

- 原假设 (H_0) = 新策略无效果
- 备择假设 (H_1) = 新策略有效果

p-value就是，如果新策略无效果（原假设为真），假如x值落在12~14（假设当前样本观察结果），或者观测结果 $x > 14$ （假设出现更极端结果），这种概率有多大。如果概率越低，那么我们越有理由拒绝 H_0

在Libra中找到“显著”

明白了p-value与显著性水平之间的关系，我们就更容易理解Libra实验报告中的正向显著、负向显著、不显著等标签。在实验报告页中，选择“显示图表”，就可以在指标表格下方看见p值标签。

- 1. p值<5%，且数据涨了，即为**正向显著**，图标底色为绿色。数据涨了，且有95%的概率该数据可以相信。
- 2. p值<5%，且数据跌了，即为**负向显著**，底色为红色。数据跌了，且有95%的概率该数据可以相信。
- 3. p值>5%，代表数据结果**不显著**，底色为白色。即可以相信这份数据的概率小于95%。




5. 统计功效 1-β

在实验中，我们也有可能出现另一种情况：我的策略其实有用，但是我没有检测出来。这便是统计学中第二类错误的表现。也就是说，在原假设是错误的前提下，实验者也可能接受原假设，这在统计学中被称为第二类错误。这种错误的概率被记为 β 。而统计功效（power，也被称为检验效力），被定义为 $1-\beta$ ，表示的是“假设我的新策略是有效的，我有多大概率在实验中检测出来。”

假设现在我们要进行一组实验，我们认为：将旧策略A调整至新策略B，能够将用户的人均观看时长提升3%。从假设检验的角度去分析我们要进行的实验可以得出，在这组实验中：

- 原假设=新策略B没用
- 备择假设=新策略B有用

同时，实验中我们不断抽样所得出的样本均值，大致会呈现正态分布。接下来看看下面这张图。



图中，左侧钟形曲线代表原假设成立时，经抽样统计，平均阅读数所呈现出的分布形态。这条曲线对应的策略实际上是“旧策略A”。假设旧策略A生效时，用户平均阅读数的真值为25s（意味着钟形曲线的中轴线在横轴上对应的值是25）；且在这一分布中，当平均阅读数均值超过25.718s时，我们会拒绝原假设，认为新策略B有效。那么。从图中来看，深灰色区域即拒绝域。

说完了左边的，我们再来看看右边的。右边钟形曲线对应的策略是新策略B。我们现在假设这一策略生效时，用户的人均观看时长真值是25.75s（即右侧钟形曲线的中轴线，在横轴上对应的值是25.75）。

先来想一下，**右边钟形曲线的真值为25.75，落在旧策略A的拒绝域里**，这意味着什么呢？这意味着，**理想状态下，新策略B其实是有效的**。但是，我们也知道，在对新策略B做抽样统计时，由于抽样误差，我们得到的平均阅读数均值大概率不会是25.75。看到图中横轴上的蓝色区域了吗？如果对新策略B做抽样统计时，其平均阅读数均值可能是蓝色区域内的任意一个数字。

- 假如在统计时，新策略B的样本均值，落在原策略A的拒绝域之中或者拒绝域右侧。此时我们可以得出结论：拒绝原假设，新策略B是有用的。
- 假如新策略B的样本均值 <25.718 ，对应上图，此时样本均值落在图中浅灰色的范围内。此时，由于样本均值并不在原策略A的拒绝域之中，所以我们没办法拒绝原假设，也就无法证明新策略B是有用的。

我们在前面已经讲到过，新策略B在抽样检验中，它的真值实际落在原策略A的拒绝域里。理论上来说，新策略B实际上是有效的。但是，如果新策略B进行抽样统计后，样本均值 <25.718 ，我们便无法检验出新策略B有效。这就犯了我们所说的**第二类错误**：“**我的策略其实有效，但是我没检验出来。**”

在上面的图中，**浅灰色区域就是我们犯第二类错误的域，其面积占右侧钟形图形面积的比率，就是我们犯第二类错误的概率**。这一概率被记作 β 。在图中的例子里， β 的取值为47%（计算过程就不展示了）。也就是说，在上面的例子里，即便我的新策略B有效，我仍有47%的概率没法检验出它是有效的。而统计效力 $=1-\beta=53\%$ 。这代表着我有53%的概率可以检测出新策略B是有效的。

实际上，统计效力的大小，取决于原假设和备择假设下，两个分布曲线的交叠关系。在此我们不再展开详细解释，有兴趣的同学可以阅读相关统计学书籍。

6. Z 检验



双侧 z 检验用于判断样本统计量是否**显著偏离零假设**，而且偏离方向不预先指定。

双侧 z 检验常见于：

- A/B 实验：判断新版本指标是否 **和旧版本不同**（不预设一定提升）
- 均值检验：样本均值是否等于某个基准值
- 比例检验：转化率是否等于某个历史值

前提条件（z 检验）：

- 样本量足够大（通常 $n \geq 30$ ，或满足中心极限定理）
- 或总体方差已知 / 可用样本方差近似

双样本均值型差 z 检验

- H_0 （原假设）： $\mu_1 = \mu_2$ （eg 两组真实均值相同）
- H_1 （备择假设）： $\mu_1 \neq \mu_2$ （eg 两组真实均值不同）

比例型 z 检验

- H_0 （原假设）： $p_1 = p_2$ （eg 两组真实转化率相同）
- H_1 （备择假设）： $p_1 \neq p_2$ （eg 两组真实转化率不同）

z 统计量公式

一、双样本均值差 z 检验 (A/B 均值)

$$z = \frac{\bar{x}_1 - \bar{x}_2}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}}$$


- z : 标准化后的均值差, 表示差距有多少个“标准误”
- $\bar{x}_1$: A 组样本均值
- $\bar{x}_2$: B 组样本均值
- $\bar{x}_1 - \bar{x}_2$: A、B 两组看到的均值差
- σ_1^2 : A 组指标的方差
- σ_2^2 : B 组指标的方差
- n_1 : A 组样本量
- n_2 : B 组样本量
- $\frac{\sigma_1^2}{n_1}$: A 组均值的方差 (均值波动)
- $\frac{\sigma_2^2}{n_2}$: B 组均值的方差
- 分母整体: 两组均值差的标准误 (SE)

二、比例 (转化率) z 检验 (A/B)

$$z = \frac{\hat{p}_1 - \hat{p}_2}{\sqrt{\hat{p}(1 - \hat{p}) \left(\frac{1}{n_1} + \frac{1}{n_2} \right)}}$$

- z : 标准化后的转化率差
- $\hat{p}_1$: A 组样本转化率
- $\hat{p}_2$: B 组样本转化率
- $\hat{p}_1 - \hat{p}_2$: A、B 两组转化率的观测差
- x_1 : A 组成功 (转化) 人数
- x_2 : B 组成功 (转化) 人数
- n_1 : A 组样本量
- n_2 : B 组样本量
- $\hat{p} = \frac{x_1 + x_2}{n_1 + n_2}$: 在原假设下估计的共同转化率
- $\hat{p}(1 - \hat{p})$: 单个用户转化结果的方差
- $\frac{1}{n_1} + \frac{1}{n_2}$: 两组样本量共同决定的缩放因子
- 分母整体: 两组转化率差的标准误 (SE)

二、AB实验流程



1. 最小样本量

样本量不是越多越好，过多样本量会造成实验资源的浪费、影响迭代效率，而过少样本会导致实验不置信，因此科学度量实验样本量，是至关重要的。

一、比例型指标（转化率 / 点击率 / 留存率）

👉 如：下单转化率、点击率、注册率

✅ 双样本比例检验样本量公式：

$$n = \frac{(Z_{1-\alpha/2} + Z_{1-\beta})^2 \cdot [p_1(1-p_1) + p_2(1-p_2)]}{(p_1 - p_2)^2}$$

参数说明：

- n ：每组样本量
- p_1 ：A组转化率（基线）
- p_2 ：B组转化率（目标）
- α ：显著性水平（一般 0.05）
- β ：第二类错误（1 - Power，一般 0.2 → Power=0.8）
- $Z_{1-\alpha/2}$ ：正态分布分位数
- $Z_{1-\beta}$ ：功效分位数

常用值：

- $\alpha = 0.05 \rightarrow Z_{1-\alpha/2} = 1.96$
- Power = 0.8 → $Z_{1-\beta} = 0.84$
- Power = 0.9 → $Z_{1-\beta} = 1.28$

二、绝对值型指标（均值类）

👉 如：人均停留时长、客单价、收入、时长、时延

✅ 双样本均值检验公式（t-test）：

$$n = \frac{2 \cdot \sigma^2 \cdot (Z_{1-\alpha/2} + Z_{1-\beta})^2}{\delta^2}$$

参数说明：

- σ ：指标标准差
- δ ：最小可检测差值（MDE）
 - 如：时长提升 5 秒 → $\delta = 5$
- 其余同上

绝对值型公式的“2” = A 组方差 + B 组方差

2. 实验周期

最小试验周期公式

$$T = \frac{2n}{UV}$$

- **T**：最小试验周期（天）
- **n**：通过样本量计算得到的**单个实验组**所需的最小用户数
- **2**：表示 AB 实验包含 **A、B 两个独立实验组**
- **UV**：每天可进入实验的**总独立用户数（日活）**

实验周期选择需要考虑三方面因素：

其一：考虑最小样本量。实验周期内累计样本量，需要大于最小样本量要求。

其二：考虑周末效应。一般产品周中和周末用户行为表现会存在差异，因此实验至少需要运行完整一周。

其三：考虑新奇效应。重点针对老用户，改版会对用户产生非持久性的行为驱动，这段时期的数据是缺乏置信度的，因此需要适当拉长实验周期。

在考虑以上因素的前提下，制定实验周期，**时间过长会导致实验迭代的效率，而时间过短会导致实验的不置信。**

3. MDE（Minimum Detectable Effect，最小可检测效应）



MDE 表示：在当前样本量和统计要求下，A/B 测试能够可靠识别的最小效果提升幅度。MDE 越小，实验对微小变化的检测能力（灵敏度）越强。

For 2-sample t test:

$$t = \frac{\Delta}{\text{std}(\Delta)} = \frac{m_1 - m_2}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \xrightarrow{H_0} N(0,1)$$

By def.

$$\text{Power} = P(|t| > z_\alpha | E(\Delta) = \delta) \text{ where}$$

$$z_\alpha = \phi^{-1}(1 - \frac{\alpha}{2}) \text{ for 2-sided test}$$

$$\text{Given } E(\Delta) = \delta, t \xrightarrow{H_1} N\left(\frac{\delta}{\text{std}(\Delta)}, 1\right)$$

Let $z = rvs \sim N(0,1)$:

$$\text{Power} = P\left(z + \frac{\delta}{\text{std}(\Delta)} > z_\alpha\right)$$

$$= P\left(z + \frac{\delta}{\text{std}(\Delta)} > z_\alpha\right) + P\left(z + \frac{\delta}{\text{std}(\Delta)} < -z_\alpha\right)$$

$$= P\left(z > z_\alpha - \frac{\delta}{\text{std}(\Delta)}\right) + P\left(z < -z_\alpha - \frac{\delta}{\text{std}(\Delta)}\right)$$

$$= 1 - \phi\left(z_\alpha - \frac{\delta}{\text{std}(\Delta)}\right) + \phi\left(-z_\alpha - \frac{\delta}{\text{std}(\Delta)}\right)$$

$$= 1 - \phi\left(z_\alpha - \frac{\delta}{\text{std}(\Delta)}\right) + (1 - \phi\left(z_\alpha + \frac{\delta}{\text{std}(\Delta)}\right))$$

$$\approx 1 - \phi\left(z_\alpha - \frac{|\delta|}{\text{std}(\Delta)}\right)$$

Solve for $|\delta|$:

$$\text{Power} = 1 - \phi\left(z_\alpha - \frac{|\delta|}{\text{std}(\Delta)}\right)$$

$$z_\alpha - \frac{|\delta|}{\text{std}(\Delta)} = \phi^{-1}(1 - \text{Power}) = \phi^{-1}(\beta)$$

$$\Rightarrow |\delta| = [\phi^{-1}(1 - \frac{\alpha}{2}) - \phi^{-1}(\beta)] \cdot \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}$$

MDE代表实验能有效检测出来的指标差异幅度。一般在实验过程中，通过MDE来评判实验的灵敏度。

- 若实验观测到的效果未达到显著性，且当前样本量对应的 $\text{MDE} > \text{业务期望提升幅度}$ ：则说明实验对该量级效果缺乏检测能力。我们可以再将实验延长一段，让更多样本进入实验，使得实验更灵敏
- 若实验观测到的效果未达到显著性，且当前样本量对应的 $\text{MDE} < \text{业务期望提升幅度}$ ：意味着现在的灵敏度已经足够检测出业务的显著提升了。但是现在实验还是不显著，那么也许是策略真的没那么有用，该再选个新策略了。

在实际的实验操作中，MDE有什么应用场景呢？

a. 实验不显著，要不要结束实验

这几乎是每个实验操作者都会遇到的问题：辛辛苦苦做了个实验，数据是涨了一点，但是实验结果不显著。咋办？现在把实验停了，换新的思路？还是让实验再跑一段时间，这会不会影响实验结果的可信性（有一点必须说明，理论上，只要你的A/B实验跑的时间足够长，样本足够多，实验总会显著的）。

在这个问题上，“MDE”就能帮你了。

当实验结果不显著时，实验者可以在实验报告中选择“多天累计指标”这一选项。在这里，我们需要查看当前实验中，我们所关注的指标，其“**检验灵敏度MDE**”是多少，并判断灵敏度是否大于指标的预期提升值：

- 如果指标的灵敏度比预期提升值大，那么我们可以将实验延长几天，再观察一段时间；

- 如果灵敏度已经比预期提升值小了，那么很遗憾，我们的实验结果没有置信的可能了，另起炉灶吧。

我们举个例子。如果在一个实验中，我期望我的新策略将平均阅读数提升3%。经过一段时间的实验后，我发现新策略下平均阅读数提升了2.5%（虽然没有预期中好，但也不错），实验结果不置信。按图索骥，此时我们应该查看平均阅读数这一指标的检验灵敏度：

- 如果MDE>3%，意味着可能你的实验可能会有3%的显著提升，只是灵敏度还不够，我们还没检验出来。所以我们可以再将实验延长一段，让更多样本进入实验，使得实验更灵敏；
- 如果MDE<3%，意味着现在的灵敏度已经足够检测出3%的显著提升了。但是现在你的实验还是不显著，那么也许是你的策略真的没那么有用。我们该再选个新策略了。



b. 实验还没开，到底要多少流量

前面的例子里，当一定流量进入实验后，我们可以了解到实验的灵敏度。反过来讲，如果用户愿意指定自己需要的灵敏度，Libra同样可以推算出实验需要多少流量。

「灵敏度不可过高/过低」

- 灵敏度太低：过低的灵敏度（比如理论上指标提升1%收益就很大了，但我们却将灵敏度设置为5%），可能导致我们与有潜力的策略失之交臂。
- 灵敏度太高：设置过高的灵敏度（需要更多样本量，更长实验时间），一方面会导致调用过多流量，形成不必要的流量浪费；另一方面，过大的流量往往会使得指标更轻易地形成显著，但其实这种显著并没有实际意义。

三、AB实验结果可能出现的问题

举个例子，某短视频APP发现其次留相对于同类APP更低，经过维度下钻分析后，发现是新用户的次留更低（这个点其实不需要分析，我们用膝盖也能想到新用户的次留比老用户更低，新用户没有发现这个产品的核心价值点）。这种情况下，分析师进行了行为事件分析：在进入APP后上滑次数（行为）与其留存率之间有较为明显的相关关系，因此决定上线“半动态化的引导样式”，见下图：

提升新用户留存 上滑引导操作实验 Round 1

实验设计

- 实验目标：提升新用户留存、上滑操作渗透率，降低错误操作渗透率
- 实验受众：APP 版本 > x.x.x 的新用户
- 流量和周期
 - 采用10%流量，对照组和实验组各占5%
 - 实验周期：一个月

实验解读

- 核心指标：新用户次留存，2留，3留均无显著提升
- 围栏指标：正确上滑渗透率-2%且显著；错误操作渗透率+4%且显著

结论：首轮实验核心指标无收益，围栏指标显著负向。停止实验，新策略下线。

原始样式：静态引导样式 VS 首轮实验：半动态式的引导样式

火山引擎 www.volcengine.cn

2021中国运营增长大会

解读实验 人人都是产品经理 www.woshipm.com

知乎 @郑华第 起点学院

遗憾的是，首轮实验核心指标无收益，围栏指标显著负向。因此决定停止实验，新策略下线？……或许我们还可以做些什么，产品经理将方案修改为“全动态的引导方案”（见下图），这一次核心指标与围栏指标的表现均符合预期了。

提升新用户留存 上滑引导操作实验 Round 2

实验解读

- 核心指标：新用户次留、3留、7留，均显著提升+8%至+10%
- 围栏指标：
 - 正确上滑渗透率+3%
 - 错误操作渗透率-1.5%

下钻多维分析

- 发达地区：上滑功能渗透率提升，新用户提升4%，高于平均水平，新引导教育作用明显
- 非发达地区：上滑渗透率无显著提升，新用户留存无提升

结论：二轮实验核心指标收益较大，围栏指标显著正向。全量新策略

原始样式：静态引导样式 VS 二轮实验：全动态式的引导样式

火山引擎 www.volcengine.cn

2021中国运营增长大会

解读实验 人人都是产品经理 www.woshipm.com

知乎 @郑华第 起点学院

1. 统计上不显著 ≠ 业务上不显著

- 统计上不显著：我们可以画一个曲线，如果实验期间每一天内实验组的核心指标都高于对照组，那我们仍然可以考虑上线策略。

- b. 样本稀释：在AB测试的过程中，真正被策略触达的用户占入组样本量比例过小，进一步导致结果不显著。举个例子，得到APP决定测试 个人中心 - 每日签到 模块带来的留存提升，但当前的分流节点在进入APP的一瞬间。有10000个人进入APP的情况下，可能只有10%的人进入了个人中心，导致最终的效果不显著。我们可以将分流节点后移，即移动到“用户进入个人中心”的节点，实验组与对照组策略如下：

组名	策略
实验组	展示个人中心模块
对照组	不展示个人中心模块

- c. A/B测试的变化有效果，但由于变化的程度很小，测试灵敏度power不足，所以没有检测到两组指标的不同

2. 统计上显著 ≠ 业务上显著？

这个可能的原因是我们在AB测试当中所选取的样本量过大，导致和总体数据量差异很小，这样的话即使我们发现一个细微的差别，它在统计上来说是显著的，在实际的案例当中可能会变得不显著了。

举个例子，对应到我们的互联网产品实践当中，我们做了一个改动，APP的启动时间的优化了0.001秒，这个数字可能在统计学上对应的P值很小，也就是说统计学上是显著的，但是在实际中用户0.01秒的差异是感知不出来的。那么这样一个显著的统计差别，其实对我们来说是没有太大的实际意义的。所以统计学上的显著并不意味着实际效果的显著。

3. 小流量实验显著，推全后不显著

首先检查实验显著时的计算方式有没有问题，如果没有问题，则可能是以下原因：

- 1) **假设检验**：AB实验本质上是假设检验，而假设检验是存在一定犯错概率的，一般设定犯第一类错误的概率为5%，即策略本身没有效果，但实验判断为有效果。也就意味着，可能出现小流量实验显著，但全量不显著的情况。
- 2) **样本量原因**：实验抽样即便满足了最小样本量的要求，但不同量级用户在指标上的稳定程度是不同的，样本量越大，波动越小。因此实验全量上线后的效果，与实验期可能存在一定差异。如果我们在10%的人群上人均增加了3%的营收，那么对全局上线该策略后，ATE（average treatment effect）可能是0%~3%
- 3) **长期效应**：一般业务都希望策略能够快速迭代上线，实验的上线周期60%小于两周、90%小于1个月，这样会导致部分长期效应在小样本实验期间无法检测出来，在推全后由于时间较久，因此长期效应显现出来

4. 边际变化不显著

举个例子，吃第一个干锅鸡翅带来的 Δ 饱腹感 > 第五个干锅鸡翅带来的 Δ 饱腹感。在做AB实验去测试补贴效果时，如果整体大盘补贴已经到了人均3元，那我们即使再补1块对用户完成订单推动是非常小的。

在这种情况下，我们需要判断大盘高补贴是普遍情况还是偶尔情况：

- 如果是普遍情况，那说明需要加大这次实验组的补贴
- 如果是偶尔情况，可以等到大盘补贴回落到正常水平例如人均1元时再做实验。

5. 观察过程指标

假设人均 GMV（核心观测指标）正向不显著，我们按照公式 人均 GMV = 人均活跃天数 $\times$ 日均 GMV 进行拆解，发现人均活跃天数有显著上升，只是日均 GMV 没上升。业务上理解就是，“人来了，但没花钱”。我们后续的策略就应该对应提升 入端 $\rightarrow$ 完单的cvr。

6. 实验组策略有效果，但power不够

A/B 测试中的变化有效果，所以两组的指标在事实上是不同的。但是由于变化的程度很小，也就是 Power 不足，所以并没有检测到两组指标的不同。那么有什么办法可以提高power（power = $1 - \beta$ ，即减小第二类错误概率 β 呢？）

可以从样本量公式中得到一些启发：

$$n = \frac{2 \cdot \sigma^2 \cdot (z_{1-\frac{\alpha}{2}} + z_{1-\beta})^2}{\delta^2}$$
$$n \delta^2 = 2 \sigma^2 (z_{1-\frac{\alpha}{2}} + z_{1-\beta})^2$$
$$\frac{n \delta^2}{2 \sigma^2} = (z_{1-\frac{\alpha}{2}} + z_{1-\beta})^2$$
$$\frac{\delta}{\sigma} \cdot \sqrt{\frac{n}{2}} = z_{1-\frac{\alpha}{2}} + z_{1-\beta}$$
$$z_{1-\beta} = \frac{\delta}{\sigma} \sqrt{\frac{n}{2}} - z_{1-\frac{\alpha}{2}}$$
$$\begin{cases} \beta \propto n \text{ 正比} \\ \beta \propto \sigma \text{ 反比} \end{cases}$$

a. 样本量和 Power 成正比。即通过增大样本量就可以提高 Power。

i. 延长测试时间，增大入组样本量。

- ii. 增加流量占比：为了以尽可能少的流量测试出实验效果，我们一开始的流量占比可能较小，在这种情况下我们可以增加在总流量中实验的流量占比来提高power。举个例子：

实验一开始只放了 很小比例流量（比如 5% vs 5%）→ 每天进入实验的用户数很少→ 到某个时间点，样本量还不够→ 提升实验组/对照组占比（比如 20% vs 20%）→ 在同样的天数内拿到更多样本→ power 提高，更容易显著

b. 方差和 Power 成反比。即通过减小方差就可以提高 Power：

- i. 采用Cuped（Controlled-experiment Using Pre-Experiment Data）降低方差。

四、CUPED 方差缩减



用实验前就已存在、且和指标强相关的变量，把噪声扣掉，从而降低方差、提升统计power。

1. CUPED核心原理

$$Y^* = Y - \theta(X - \mathbb{E}[X])$$

$$\text{Var}(Y^*) = \text{Var}(Y) (1 - \rho_{XY}^2)$$

逐项解释：

- Y：实验期观测到的原始指标（如实验期转化率 / GMV / 点击数）
- X：实验前的协变量指标（如历史转化率 / 历史 GMV / 历史点击）
- $\mathbb{E}[X]$ ：实验前协变量在全体用户上的平均值
- Y^* ：CUPED 调整指标
- θ ：使调整后指标方差最小的最优线性调整系数
- ρ ：X 和 Y 的相关系数

直观理解一下：利用实验前的用户行为数据（X）与预测实验指标（Y），剔除个体差异带来的噪声，使实验组与对照组的对比更聚焦于「因果效应」。同时，X与Y的相关性越强， ρ 越大，方差缩减效果越显著。

2. 举个例子

案例背景：今日头条计划对首页进行改版（工具区、猜喜区等模块样式优化），希望通过AB实验验证新版首页是否能提升用户GMV（成交总额）

核心指标：用户7日GMV

AB实验难点：

- GMV方差大：长尾分布，少量用户贡献大部分GMV。
- 所需用户量大：检测2%的GMV提升需要10万用户，耗时14天，流量成本高。

Step 1: 选择协变量 (Covariate)

目标：找到与目标指标（GMV）强相关，且不受实验干预影响的变量。根据业务历史经验，选择候选变量如下：

用户ID	实验前30天购买次数	实验前30天活跃天数	实验前30天平均点击量	实验组 / 对照组	实验7日GMV (原始)
1001	8	25	120	实验组	450
1002	2	10	30	对照组	80
1003	15	30	200	实验组	1200

通过Pearson相关系数，计算实验前各变量与GMV的相关性。

- 实验前30天购买次数 vs GMV： $\rho=0.68$
- 实验前30天活跃天数 vs GMV： $\rho=0.52$
- 实验前30天平均点击量 vs GMV： $\rho=0.45$

选择「相关性最大的变量作为协变量」，这里选择「实验前30天购买次数」。

Step 2: 计算调整系数 θ

通过线性回归 $Y = \theta X + \epsilon$ ，估计X对Y的预测系数 θ

代码块

```
1 import numpy as np
2 from sklearn.linear_model import LinearRegression
3
4 # 从实验组和对照组全量数据中抽取样本 (N=100000)
5 X = np.array([8, 2, 15, ..., 5, 12]) # 实验前购买次数
6 Y = np.array([450, 80, 1200, ..., 200, 600]) # 实验7日GMV
```

```
7
8 # 拟合线性模型
9 model = LinearRegression().fit(X.reshape(-1,1), Y)
10
11 theta = model.coef_ # 输出: theta=52.3
```

通过计算得出，用户每增加1次历史购买，实验期GMV平均增加52.3元。

Step 3: 计算调整后的GMV

这里，假设全量用户的历史购买次数均值 $E[X] = 6.2$ ，单用户指标调整如下。

用户ID	X (历史购买)	Y (原始 GMV)	Y_adjusted (调整后 GMV)
1001	8	450	$450 - 52.3 \times (8 - 6.2) = 355.6$
1002	2	80	$80 - 52.3 \times (2 - 6.2) = 300.7$
1003	15	1200	$1200 - 52.3 \times (15 - 6.2) = 739.3$

这样调整，大家应该可以发现，高历史购买用户（如1003）的原始GMV被向下修正，避免个体差异掩盖实验效应；低历史购买用户（如1002）的GMV被向上修正，提升组间可比性。

Step 4: 评估方差缩减效果

这里，对比下「原始GMV」与「调整后GMV」的统计数据差异。

指标	原始 GMV	调整后 GMV	变化率
方差 (σ^2)	120,000	69,600	-42%
均值 (元)	320	320	0%

可以发现，方差减少42%，检测灵敏度提升，如下样本量测算公式，所需样本量减少58%。

Step 5: 假设检验与业务结论

通过采用检验统计量，验证实验效果。

指标	实验组均值	对照组均值	P 值	置信区间 (95%)
原始 GMV	332 元	308 元	0.06	[-5, +49]
调整后 GMV	340 元	300 元	0.01	[+18, +52]

通过以上数据可以看出，使用CUPED后，GMV提升的统计显著性从 $P=0.06$ （不显著）提升至 $P=0.01$ （显著），改版后首页GMV提升约13%（调整后均值差40元），置信区间排除零效应，项目可上线。

3. 注意事项

- a. 协变量选择有讲究。协变量最好选择「强相关性、无干预影响、高覆盖率」的指标，避免出现短期波动，例如：不要选择「过去1天购买次数」这种指标。
- b. 剔除极端值，防止过拟合。对于核心指标较大的用户，例如：GMV>10w的用户，单独分析，不进入主要回归流程。

五、AA实验



AA 实验（A/A Test）指开启一个实验组和对照组配置一模一样的实验。

AA 实验的目的通常是为了验证两组实验用户之间没有显著差别，因此 AA 实验通常被用于验证实验的健全性，为 AB 实验（A/B Test）做准备。